Как сравнивать бизнес-домены кандидата и вакансии

Архитектура скоринга: дополнение контекста, граф связей доменов и реранкер

Проблематика

1

Разные формулировки

Один и тот же опыт в резюме и вакансии описан разными словами

2

Короткие описания

Эмбеддинги коротких фраз плохо отличают близкие домены от далёких

3

Нет полного списка

Домены вложены друг в друга, а справочника не существует

Решение проблемы

1

Не сравнивать голые фразы

Короткие фразы из резюме слишком сложно сравнивать

2

Граф связей доменов

Синонимы, вложенность и смежные области хранятся в графе

3

Обогащение контекстом

К домену кандидата добавляем выжимку и ответы на фиксированные вопросы

4

Реранкер

Сопоставляет запрос рекрутера с расширенным доменом кандидата

Чистим вход и разделяем требования

Резюме

- LLM исправляет опечатки
- Убирает не-доменные факты, например «работа в команде»
- Удаляет дублирующиеся факты

Запрос рекрутера

Выделяются домены, которые нужно найти у кандидатов

На выходе: чистые доменные факты резюме и домены запроса

Главные домены и обогащение

- LLM определяет домены из резюме
- Достраивает отрасль через граф: «реализация ядра в банке» → финтех
- К каждому домену добавляются выжимка из контекста и ответы на фиксированные вопросы
- Обогащённый домен лучше сравнивается эмбеддингами

Пример карточки домена

Домен

интеграция банковского ядра

Отрасль

финтех (достроено через граф)

Тип организации

банк

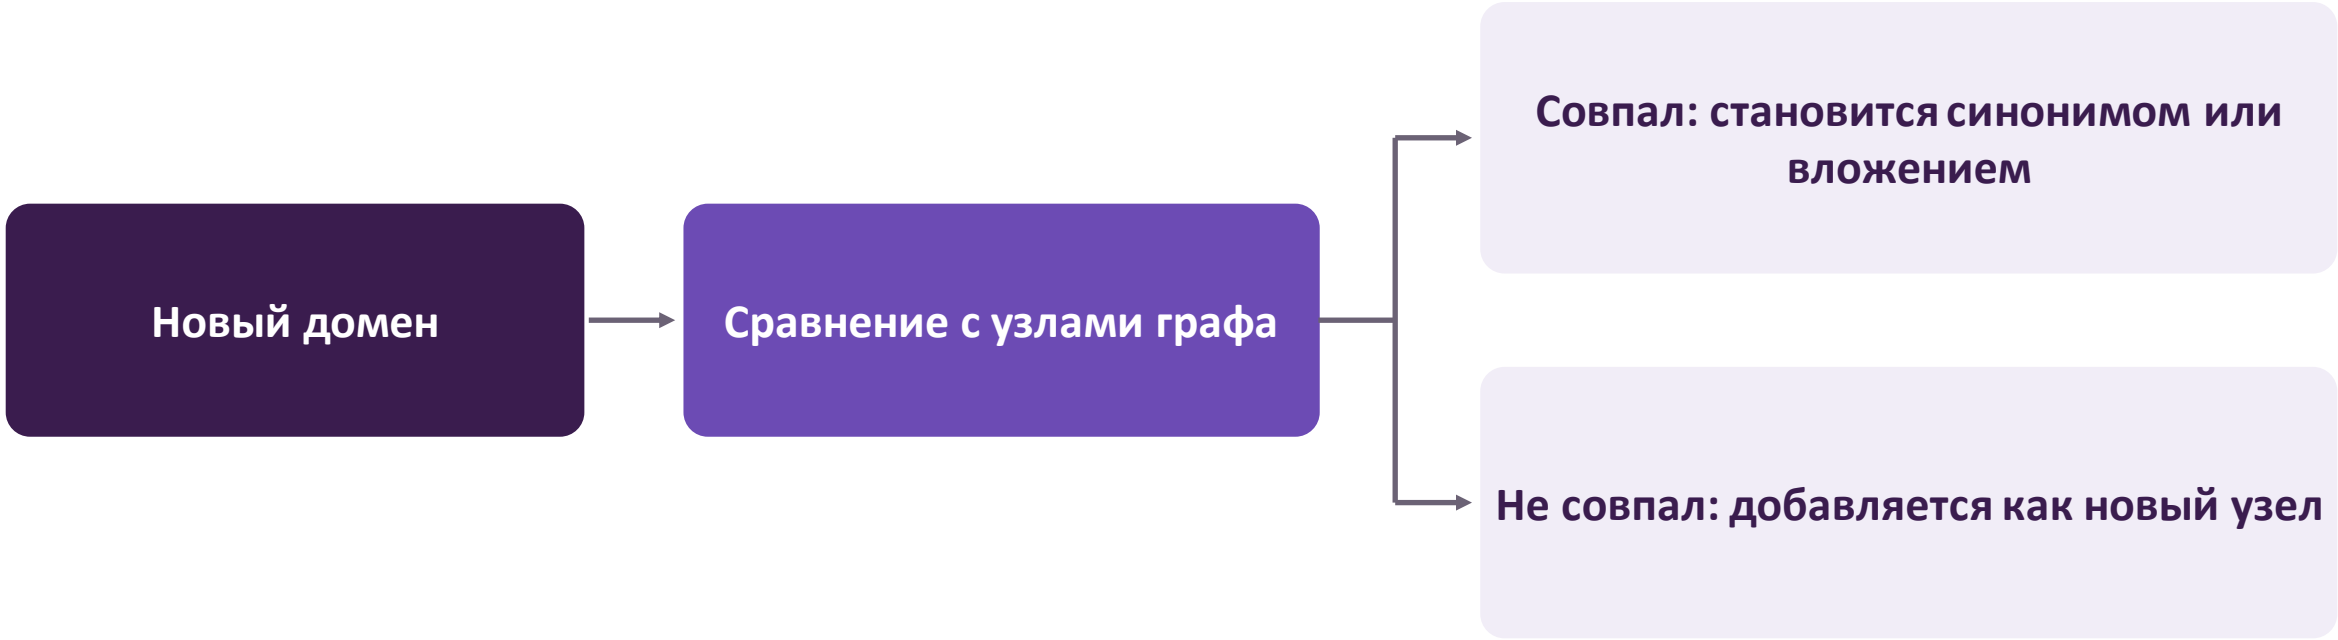
Бизнес-процесс

обмен данными между системами

В чём заключалась работа

интеграция с внешними сервисами

Граф связей доменов



Поиск и скоринг

1 Фильтр по главным доменам	«нужен специалист из финтеха» → финтех среди главных доменов кандидата
2 Ближайшие домены в графе	по близости к запросу рекрутера
3 Топ 50 результатов	ближайших элементов
4 Реранкер	оценивает пару: запрос рекрутера и домен кандидата

Точная оценка близости

01

Топ 50 и домен из запроса рекрутера идут в реранкер

02

Реранкер оценивает, насколько опыт кандидата закрывает требование

03

Оценка переводится в балл

04

Итог добавляется признаком в общий скоринг: роль, seniority, стек

Нагрузка для 10 000 кандидатов

10 000

кандидатов в базе

Масштаб, на который рассчитана схема

1 раз

тяжёлая обработка

LLM, обогащение и граф считаются при загрузке резюме

50

элементов в реранкер

На запрос остаются поиск в графе и реранкинг сотни

Новые резюме обрабатываются по одному, без пересчёта всей базы

Анализ и сбор метрик

На чём проверяем	Пары доменов с градациями (то же, близкое, смежное, чужое) и запросы рекрутера с разметкой подходящих кандидатов
Что сравниваем	Сырая фраза, обогащённая, обогащённая + реранкер
Метрики	Можно использовать nDCG@10, MRR, recall@K
Human feedback	Обратная связь рекрутеров как дополнительная разметка

Итог

1. Домены сравниваются через контекст и граф, а не через исходные строки
2. Реранкер видит запрос рекрутера и принимает финальное решение
3. Граф растёт сам, полный список доменов не нужен
4. Решение масштабируется и проверяется на размеченных данных