Тестовое задание

Представьте, что вы строите систему скоринга соответствия **вакансии и кандидата**.
Сейчас она хорошо работает по понятным сущностям: роль, seniority, стек, обязательные навыки. Но отдельная сложная задача, которую отдали в вашу зону ответственности: **бизнес-домены**.

Контекст

У каждого кандидата из резюме извлекаются бизнес-домены, например:

- биллинг
- анализ кредитных заявок
- CRM-интеграция
- автоматизация бизнес-процессов
- промышленный IoT
- MES-система
- кредитное оформление

Проблема в том, что формулировки бизнес-доменов в вакансии и в резюме могут сильно отличаться, а прямое сравнение через эмбеддинги дает слабоотличаемый друг от друга результат.

Например, запрос:

> *Нужен автотестировщик senior-уровня с обязательным отличным знанием Kafka и обязательным опытом работы в финтехе.*

обрабатывается хорошо, потому что Финтех – это глобальный домен, который может быть легко класифицирован по белому списку глобальных доменов с помощью LLM.

Но если добавить уточнение:

> *У кандидата желателен опыт с интеграцией банковского ядра*

то становится неочевидно, как корректно учесть такую бизнес-доменную близость в скоринге, в первую очередь потому что нет точной DB/списка всех возможных бизнес доменов, которые можно с высоким шансом всегда можно присваивать кандидату на этапе внесения его резюме в DB, даже с помощью LLM или подсчетом эмбендингов (но возможно можно тут что то придумать).

Задача

Предложите подход, который позволит:

- извлекать бизнес-домены из резюме и пользовательских запросов;
- определять, какие домены похожи или относятся к одной предметной области;
- использовать это в скоринге вакансии и кандидата;
- сделать решение масштабируемым на массиве порядка 10 000 кандидатов.

Что мы хотим увидеть

Опишите:

- как бы вы решали эту задачу;
- какой пайплайн или архитектуру предложили бы;
- как сравнивали бы бизнес-домены между собой;
- как проверяли бы качество решения;
- какие подходы использовали бы: эмбеддинги, LLM, классификацию, RAG, гибридную механику и т.д.
- если возможно покажите mvp решения на предоставленных нами синтетических данных.

Формат ответа

Свободный: документ, презентация, markdown, схема, ноутбук с пояснениями.